

# Учебник по Эконометрике

## Лекция 4: Моделирование зависимости

Джон Стачурски

Лекции: Акшай Шенкер

Перевел: Алексей Кедо

8 октября 2020 г.



- во время умножения матриц случайные векторы по умолчанию будут векторами-столбцами

Пространство элементарных событий — это единичный диск  $\Omega := \{(h, v) \in \mathbb{R}^2 : \|(h, v)\| \leq 1\}$  и пространство событий — это Борелевские множества в  $\Omega$

Если  $x$  тождественен  $\Omega$ , то он просто сообщает результат  $(h, v)$  — случайный вектор

Вектор  $(y_1, \dots, y_N)$  который сообщает результат этой выборки, можно рассматривать как случайный вектор в  $\mathbb{R}^N$







**Факт.** (??) Если  $X$  и  $Y$  — случайные матрицы или векторы, и  $A$  и  $B$  постоянны и согласованны, то

$$\mathbb{E}[\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}] = \mathbf{A}\mathbb{E}[\mathbf{X}] + \mathbf{B}\mathbb{E}[\mathbf{Y}]$$





**Факт.** Для любого случайного вектор  $\mathbf{x}$  с  $\mathbb{E}[\mathbf{x}^T \mathbf{x}] < \infty$ ,

1.  $\text{var}[\mathbf{x}]$  существует и неотрицательно определена,
2.  $\text{var}[\mathbf{x}] = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] - \boldsymbol{\mu}\boldsymbol{\mu}^\top$ , и
3.  $\text{var}[\mathbf{A}\mathbf{x} + \mathbf{b}] = \mathbf{A} \text{var}[\mathbf{x}] \mathbf{A}^\top$  (для любых постоянных и согласованных  $\mathbf{A}, \mathbf{b}$ ).

**Кросс-ковариация** между случайными векторами  $x$  и  $y$  определяется как

$$\text{cov}[\mathbf{x}, \mathbf{y}] := \mathbb{E}[(\mathbf{x} - \mathbb{E}[\mathbf{x}])(\mathbf{y} - \mathbb{E}[\mathbf{y}])^\top]$$

Очевидно,  $\text{var}[\mathbf{x}] = \text{cov}[\mathbf{x}, \mathbf{x}]$

**Факт.** (??) Если  $\mathbf{z}$  — случайный вектор в  $\mathbb{R}^N$ , удовлетворяющий  $\mathbb{E}[\mathbf{z}\mathbf{z}^\top] = \mathbf{I}$  и  $\mathbf{A}$  любая постоянная матрица размера  $N \times N$ , то

$$\mathbb{E} [\mathbf{z}^\top \mathbf{A} \mathbf{z}] = \text{trace } \mathbf{A}$$

Доказательство — решенное упражнение (смотрите упр. ??)

## Совместные распределения

**Распределение** или **закон**  $P$  в  $\mathbb{R}^N$  — вероятностная мера Борелевских множеств  $\mathcal{B}(\mathbb{R}^N)$

По определению, оно удовлетворяет  $P(\mathbb{R}^N) = 1$  и  $P(\cup_{n=1}^{\infty} B_n) = \sum_{n=1}^{\infty} P(B_n)$  для любых непересекающихся последовательностей  $\{B_n\}$  в  $\mathcal{B}(\mathbb{R}^N)$




Рис.: Пример распределения и события  $A$  и  $B$

Любое распределение  $P$  в  $\mathbb{R}^N$  характеризуется функцией

$$F(\mathbf{s}) := F(s_1, \dots, s_N) := P\left(\times_{n=1}^N (-\infty, s_n]\right) \quad (\mathbf{s} \in \mathbb{R}^N)$$

Функция  $F$  — **функция совместного распределения**, которая является функцией  $F: \mathbb{R}^N \rightarrow [0, 1]$  со следующими свойствами

1. непрерывна справа по каждому из своих аргументов,
2. возрастает по каждому из своих аргументов, и
3. удовлетворяет

$$F(\mathbf{s}_j) \rightarrow 1 \text{ при } s_j \rightarrow \infty$$

$$\text{и } F(s_1, \dots, s_{nj}, \dots, s_N) \rightarrow 0 \text{ при } s_{nj} \rightarrow -\infty$$

Распределение  $P$  в  $\mathbb{R}^N$ :

- **дискретно**, если  $P$  имеет носитель распределения в счетном подпространстве  $\mathbb{R}^N$
- **абсолютно непрерывно**, если  $P(B) = 0$  всюду, где  $B$  имеет меру Лебега равную нулю

Опять же, абсолютная непрерывность необходима и достаточна для существования функции плотности:

$$P(B) = \int_B p(\mathbf{s}) \, d\mathbf{s} \quad \text{для всех } B \in \mathcal{B}(\mathbb{R}^N)$$

справа — многомерный интеграл, который мы можем записать как

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \mathbb{1}_B(s_1, \dots, s_N) p(s_1, \dots, s_N) \, ds_1 \cdots ds_N$$

Если  $p$  — любая функция плотности в  $\mathbb{R}^N$ , то вышенаписанное определяет распределение




**Пример.** Многомерное нормальное распределение или многомерное распределение Гаусса в  $\mathbb{R}^N$  — функция  $p$  вида

$$p(\mathbf{s}) = (2\pi)^{-N/2} \det(\mathbf{\Sigma})^{-1/2} \exp \left\{ -\frac{1}{2} (\mathbf{s} - \boldsymbol{\mu})^T \mathbf{\Sigma}^{-1} (\mathbf{s} - \boldsymbol{\mu}) \right\}$$

где  $\boldsymbol{\mu}$  — любой вектор размера  $N \times 1$  и  $\mathbf{\Sigma}$  — положительно определенная матрица размера  $N \times N$

Представим это распределение как  $N(\boldsymbol{\mu}, \mathbf{\Sigma})$

Случай  $N(\mathbf{0}, \mathbf{I})$  называется **многомерным стандартным нормальным распределением**



**Рис.:** Функция плотности двумерного стандартного нормального распределения

**Распределение произведения**  $P_1, \dots, P_N$  определяется следующим фактом:

**Факт.** (??) Возьмем распределения  $P_1, \dots, P_N$  в  $\mathbb{R}$ , существует единственное и определенное распределение  $\mathring{P}$  в  $\mathbb{R}^N$ , такое что

$$\begin{aligned} & \mathring{P}(B_1 \times \dots \times B_N) \\ &= \prod_{n=1}^N P_n(B_n) \quad \text{для всех } B_n \in \mathcal{B}(\mathbb{R}), n = 1, \dots, N \end{aligned}$$

Единственное, потому что распределения однозначно закреплены цилиндрическими множествами  $\mathbb{R}^N$  (смотрите страницу 128 в ЕТ)

Возьмем любое распределение  $P$  в  $\mathbb{R}^N$ ,  $n$ -ое **частное распределение**  $P$  — это распределение в  $\mathbb{R}$  определенное как

$$P_n(B) = P(\mathbb{R} \times \cdots \times \mathbb{R} \times B \times \mathbb{R} \times \cdots \times \mathbb{R})$$

Здесь  $B$  —  $n$ -ый элемент Декартового произведения

Эквивалентно,

$$P_n(B) = P\{\mathbf{s} \in \mathbb{R}^N : \mathbf{s}^\top \mathbf{e}_n \in B\}$$

Из  $P_n$  мы можем также получить **частную функцию распределения**  $F_n$  с помощью

$$F_n(s) := P_n((-\infty, s]) \quad (s \in \mathbb{R})$$

(смотрите страницу ?? в ЕТ)

Если  $P_n$  абсолютно непрерывная, она имеет функцию плотности  $p_n$

Если совместное распределение  $P$  имеет функцию плотности  $p$ , частное распределение  $P_n$  имеет функцию плотности  $p_n$  – “интегрировать по другим переменным”

Например, двумерный случай:

$$p_1(s_1) = \int_{-\infty}^{\infty} p(s_1, s_2) ds_2$$



**Рис.:** Двумерная совместная функция плотности и две ее частных вариации

Совместное распределение не может быть получено только из частных

- частные не говорят нам о своем взаимодействии

Исключение составляют случаи отсутствия взаимодействия - случай произведения функций распределения





или, в векторной форме

$$F(\mathbf{s}) = \mathbb{P}\{\mathbf{x} \leq \mathbf{s}\} \quad (\mathbf{s} \in \mathbb{R}^N)$$

26/106

Пусть  $P_n = \mathcal{L}(x_n)$ , тогда:

$$P_n(B) = \mathbb{P}\{x_n \in B\} \quad (B \in \mathcal{B}(\mathbb{R}), n = 1, \dots, N)$$

$P_n$  называется **частным распределением**  $x_n$

Если  $P_1 = P_2 = \dots = P_N$ , то  $x_1, \dots, x_N$  **одинаково  
распределены**

Мы пишем  $\mathcal{L}(x) = N(\mu, \sigma)$

Случайный вектор  $x$  в  $\mathbb{R}^N$  **многомерный нормальный**, если

$$\mathbf{x} = \boldsymbol{\mu} + \mathbf{C}\mathbf{z}$$

где  $\mathbf{z}$  — стандартный нормальный случайный вектор размера  $K \times 1$ , матрица  $\mathbf{C}$  имеет размер  $N \times K$  и вектор  $\boldsymbol{\mu}$  имеет размер  $N \times 1$

Если  $x$  многомерный нормальный, то мы пишем

$$\mathcal{L}(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \text{ где}$$

$$\mu := \mathbb{E} \mathbf{x} \quad \text{и} \quad \Sigma := \text{var } \mathbf{x}$$

Имеется  $\Sigma = \mathbf{C}\mathbf{C}^\top$  (вспомним факт 5.1.2 в ЕТ)

30/106

**Факт. (??)** Пусть  $x$  — случайный вектор в  $\mathbb{R}^N$ . Следующие утверждения верны:

1. вектор  $\mathbf{x}$  многомерный нормальный тогда и только тогда, когда  $\mathbf{a}^T \mathbf{x}$  нормально распределено в  $\mathbb{R}$  для каждого постоянного вектора  $\mathbf{a}$  размера  $N \times 1$
2. Если  $\mathcal{L}(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ , то

$$\mathcal{L}(\mathbf{Ax} + \mathbf{b}) = \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$$

для всех постоянных согласованных  $\mathbf{A}, \mathbf{b}$

Следствие: если  $\mathbf{x} = (x_1, \dots, x_N)$  многомерный нормальный, то частное распределение  $x_n$  одномерное нормальное

Всегда ли совместное распределение  $N$  одномерных нормальных случайных величин является многомерным нормальным?

- Ответ: нет





34/106

35/106



37 / 106

$$F(s_1, \dots, s_N) = \prod_{n=1}^N F_n(s_n)$$

$$F(s_1, \dots, s_N) = \prod_{n=1}^N F_n(s_n)$$

для всех  $(s_1, \dots, s_N) \in \mathbb{R}^N$ , где  $F$  функция распределения  $x$  и  $F_1, \dots, F_N$  частные функции распределения (почему?)

Если распределение  $x$  абсолютно непрерывное, мы можем также проверить независимость с помощью его функции плотности:

**Факт. (??)** Если  $\mathbf{x} = (x_1, \dots, x_N)$  имеет совместную функцию плотности  $p$  и частные  $p_1, \dots, p_N$ , то  $x_1, \dots, x_N$  независимы тогда и только тогда, когда

$$p(s_1, \dots, s_N) = \prod_{n=1}^N p_n(s_n) \quad \text{для всех } (s_1, \dots, s_N) \in \mathbb{R}^N$$







**Факт.** (??) Если  $x_1, \dots, x_N$  независимые и каждый  $x_n$  интегрируемый, то

$$\mathbb{E} \left[ \prod_{n=1}^N x_n \right] = \prod_{n=1}^N \mathbb{E} [x_n]$$



44/106

**Факт.** (??) Если  $x$  многомерно нормально распределен и  $A$  и  $B$  согласованные постоянные матрицы, то  $Ax$  и  $Bx$  независимые тогда и только тогда, когда  $\text{cov}(Ax, Bx) = 0$



Суммы произвольных нормальных не всегда нормальны — нам требуется многомерное нормальное распределение

В факте (??) выше:

$$\mathcal{L}(w_1, \dots, w_N) = N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

где  $\mathbf{e}_n^T \boldsymbol{\mu} = \mu_n$ , и

$$\boldsymbol{\Sigma} = \text{diag}(\sigma_1^2, \dots, \sigma_N^2)$$

**Копула**  $C$  в  $\mathbb{R}^N$  — многомерная функция распределения определённая на единичном гиперкубе  $[0, 1]^N$ , такая что каждое ее частное распределение равномерно на  $[0, 1]$

$C$  — функция вида

$$C(s_1, \dots, s_N) = \mathbb{P}\{u_1 \leq s_1, \dots, u_N \leq s_N\} \quad (5)$$

Где  $0 \leq s_n \leq 1$  и  $\mathcal{L}(u_n) = U[0, 1]$  для всех  $n$

Пока каждый  $u_n$  имеет фиксированное частное распределение, существует бесконечно много способов составить совместное распределение



**Пример.** Функция  $C(s_1, s_2) = s_1 s_2$  на  $[0, 1]^2$  называется  
**независимая копула**

Частные распределения  $C(s_1, 1) = s_1$  и  $C(1, s_2) = s_2$  как и  
требуется

(Это функции распределения для  $U[0, 1]$  распределения)

**Пример.** Копула Гумбеля — класс функций в  $[0, 1]^2$ , определяемый как

$$C(s_1, s_2) = \exp \left\{ - \left[ (-\ln s_1)^\theta + (-\ln s_2)^\theta \right]^{1/\theta} \right\}, \quad (\theta \geq 1)$$

**Копула Клейтона** определяется как

$$C(s_1, s_2) = \left\{ \max \left[ s_1^{-\theta} + s_2^{-\theta} - 1, 0 \right] \right\}^{-1/\theta}, \quad (\theta \geq -1, \theta \neq 0)$$

Обе они принадлежат к общему классу, называемому **Архимедовы копулы**

Мы можем взять равномерные функции распределения  $F_1, \dots, F_N$  и копулу  $C$ , чтобы создать многомерную функцию распределения в  $\mathbb{R}^N$  с помощью

$$F(s_1, \dots, s_N) = C(F_1(s_1), \dots, F_N(s_N))$$
$$(s_n \in \mathbb{R}, n = 1, \dots, N) \quad (6)$$

Польза: разделяем определение частных и определение совместного распределения

**Пример.** `bonhomme2009assessing` использует копулы для моделирования одного компонента динамики заработка в исследовании, основанном на трехлетних панельных данных (French Labor Force Survey)

Разделы относительно большие (около 30 000), что позволяет гибко моделировать частные распределения с помощью смеси нормальных

Однако, размер временного ряда короткий, поэтому используется семейство копул с одним параметром для привязки частных во времени не трудозатратным способом

**Теорема.** (??) Если  $F$  — некоторая функция распределения в  $\mathbb{R}^N$  с частными  $F_1, \dots, F_N$ , то существует копула  $C$ , такая что (6) выполняется. Если каждый  $F_n$  непрерывен, то это представление является единственным.

Если  $F_1, \dots, F_N$  равномерные нормальные, то  $C(F_1(s_1), \dots, F_N(s_N))$  будут равняться многомерной нормальной функции распределения для одного варианта копулы, называемой Гауссовой копулой

Другие варианты приводят к другим распределениям

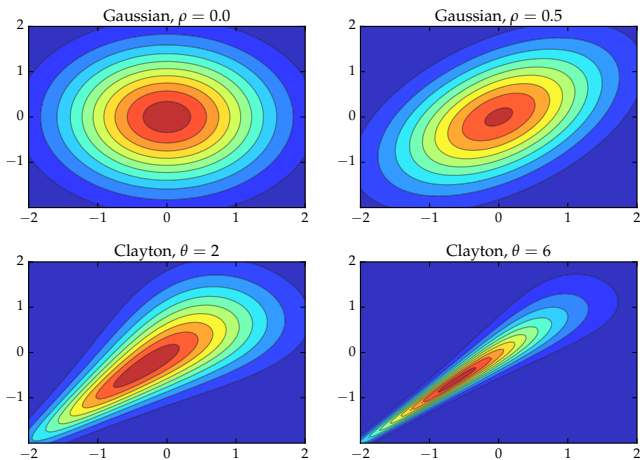


Рис.: Двумерный Гауссовская (вверху) и не-Гауссовская (внизу)

## Свойства именных распределений

**Факт.** (??) Если  $x_1, \dots, x_N$  независимые и  $\mathcal{L}(x_n) = \chi^2(k_n)$ , то  $\mathcal{L}(\sum_n x_n) = \chi^2(\sum_n k_n)$

**Факт.** (??) Если  $z$  и  $x$  независимые с  $\mathcal{L}(z) = N(0, 1)$  и  $\mathcal{L}(x) = \chi^2(k)$ , то

$z\sqrt{\frac{k}{x}}$  распределено как  $t$  с  $k$  степенями свободы



**Факт. (??)** Если  $\mathcal{L}(z_1, \dots, z_N) = N(\mathbf{0}, \mathbf{I})$ , то  $\mathcal{L}(\sum_{n=1}^N z_n^2) = \chi^2(N)$ .

**Факт. (??)** Если  $\mathcal{L}(\mathbf{z}) = N(\mathbf{0}, \mathbf{I})$  и  $\mathbf{A}$  симметрична и идемпотентна, то

$$\mathcal{L}(\mathbf{z}^T \mathbf{A} \mathbf{z}) = \chi^2(K) \quad , \text{ где } K := \text{trace } \mathbf{A}$$

Упражнение: получите факт (??) из факта (??). (Смотрите страницу ?? в ЕТ)

## Условия и ожидание

Условное ожидание — одно из важнейших понятий как в экономической теории, так и в эконометрике

В этом разделе дается построение математического ожидания, основанное на проекции:

- условное математическое ожидание как оптимальное предсказание с учетом ограниченной информации

## Условные функции плотности

Сначала обсуждение условных функций плотности

Пусть  $x_1$  и  $x_2$  — случайные величины. **Условная функция плотности**  $x_2$  при заданном  $x_1 = s_1$  определяется как

$$p(s_2 | s_1) := \frac{p(s_1, s_2)}{p(s_2)}$$

Здесь  $p$  может обозначать совместную, частную или условную функцию плотности, определяемую аргументом

Закон полной вероятности расширяется до случая с функциями плотности следующим образом: Если  $(x_1, x_2)$  — случайный вектор в  $\mathbb{R}^2$ , то

$$p(s_2) = \int_{-\infty}^{\infty} p(s_2 | s_1) p(s_1) ds_1 \quad (s_2 \in \mathbb{R})$$

**Доказательство.** Зафиксируем  $s_2 \in \mathbb{R}$  и проинтегрируем совместную функцию плотности, чтобы получить частную, получается

$$p(s_2) = \int_{-\infty}^{\infty} p(s_1, s_2) ds_1$$

Сочетаем с  $p(s_2 | s_1) = p(s_1, s_2) / p(s_1)$ , чтобы получить результат

Закон Байеса также расширяется до случая с функциями плотности:

$$p(s_2 | s_1) = \frac{p(s_1 | s_2)p(s_2)}{p(s_1)}$$

Условная функция плотности  $x_{k+1}, \dots, x_N$  при  $x_1 = s_1, \dots, x_k = s_k$  определяется как

$$p(s_{k+1}, \dots, s_N \mid s_1, \dots, s_k) = \frac{p(s_1, \dots, s_N)}{p(s_1, \dots, s_k)}$$

Перегруппируйте, чтобы получить полезное разложение совместной функции плотности:

$$p(s_1, \dots, s_N) = p(s_{k+1}, \dots, s_N \mid s_1, \dots, s_k) p(s_1, \dots, s_k)$$

Предположим, мы хотим предсказать случайную переменную  $y$  с помощью другой переменной  $x$

Возьмем  $x$  такой, что  $x$  и  $y$ , как ожидается, будут близки при большинстве реализаций неопределенности

Но что значит "ожидаются близкими"?

## Среднеквадратическая ошибка (MSE)

$$\mathbb{E}[(x - y)^2]$$

## Среднеквадратическое отклонение:

$$\|x - y\| := \sqrt{\mathbb{E}[(x - y)^2]} \quad (7)$$

Есть много параллелей между обычным векторным пространством с евклидовой нормой и множеством случайных величин в сочетании с "нормой", определенной в (7) — мы формализуем эти идеи далее



Первым геометрическим понятием, которое мы определили для векторов, было скалярное произведение

Аналогично, определим **скалярное произведение между двумя случайными величинами**  $x$  и  $y$

$$\langle x, y \rangle := \mathbb{E}[xy]$$

Неравенство Коши — Буняковского для случайных величин говорит нам, что  $\mathbb{E}[xy]$  должен быть конечным и определенным всюду, где  $x$  и  $y$  оба имеют конечные вторые моменты

Множество случайных величин с конечными вторыми моментами обычно обозначается как  $L_2$

$$L_2 := \{ \text{все случайные величины } x \text{ в } (\Omega, \mathcal{F}, \mathbb{P}) \text{ с } \mathbb{E}[x^2] < \infty \}$$

**Факт.** (??) Для любых  $\alpha, \beta \in \mathbb{R}$  и любых  $x, y, z \in L_2$  следующие утверждения верны:

1.  $\langle x, y \rangle = \langle y, x \rangle$ .
2.  $\langle \alpha x, \beta y \rangle = \alpha \beta \langle x, y \rangle$ .
3.  $\langle x, \alpha y + \beta z \rangle = \alpha \langle x, y \rangle + \beta \langle x, z \rangle$ .

Свойства следуют из определения скалярного произведения и линейности  $\mathbb{E}$

Сравните приведенное выше с фактом ?? в ЕТ для векторов в евклидовом пространстве

Определим  $L_2$  норму как

$$\|x\| := \sqrt{\langle x, x \rangle} := \sqrt{\mathbb{E}[x^2]} \quad (x \in L_2)$$

Норма дает понятие расстояния  $\|x - y\|$  между случайными величинами что согласуется с понятием среднеквадратического отклонения

**Факт.** (??) Для любых  $\alpha \in \mathbb{R}$  и любых  $x, y \in L_2$ , следующие утверждения верные:

1.  $\|x\| \geq 0$  и  $\|x\| = 0$  тогда и только тогда, когда  $x = 0$
2.  $\|\alpha x\| = |\alpha| \|x\|$
3.  $\|x + y\| \leq \|x\| + \|y\|$
4.  $|\langle x, y \rangle| \leq \|x\| \|y\|$

Свойство 2. приведенного выше факта является непосредственным из определения нормы и линейности  $\mathbb{E}$

Свойство 3. называется **неравенством треугольника**, как и в векторном случае

Свойство 4. — это просто **неравенство Коши — Буняковского** для случайных величин со страницы ??

Как и в векторном случае, неравенство треугольника доказывается неравенством Коши - Буняковского (смотрите упражнение ??)

Относительно 1.,  $\|x\| = 0$  не подразумевает, что  $x(\omega) = 0$  для всех  $\omega \in \Omega$

Мы можем сказать, что если  $\|x\| = 0$ , то  $\mathbb{P}\{x = 0\} = 1$

При работе с  $L_2$ , принято соглашение не различать случайные величины, различающиеся с нулевой вероятностью.

## Линейные подпространства в $L_2$

Любая **линейная комбинация** случайных величин с конечной дисперсией

$$\alpha_1 x_1 + \cdots + \alpha_K x_K, \quad \alpha_k \in \mathbb{R}, x_k \in L_2 \quad (8)$$

снова в  $L_2$

Когда  $X$  — подпространство  $L_2$ , множество конечных линейных комбинаций, которое может быть сформировано из элементов  $X$ , называется **линейной оболочкой**  $X$ , и обозначается как  $\text{span } X$

**Пример.** Если  $x \in L_2$  и  $\mathbb{1} := \mathbb{1}_\Omega$  постоянная случайная переменная, всегда равная 1, то  $\text{span}\{\mathbb{1}, x\}$  — множество случайных величин

$$\alpha + \beta x := \alpha \mathbb{1} + \beta x \quad \text{для скаляров } \alpha, \beta \quad (9)$$

Это множество  $\mathcal{L}$  введенное, когда мы обсуждали лучшие линейные предикторы

Подмножество  $S$  множества  $L_2$  называется **линейным подпространством**  $L_2$ , если оно замкнуто относительно сложения и умножения на скаляр

- для каждого  $x, y \in S$  и  $\alpha, \beta \in \mathbb{R}$ , мы имеем  $\alpha x + \beta y \in S$

**Пример.** Линейная оболочка любого множества элементов  $L_2$  — линейное подпространство в  $L_2$



**Пример.** Множество  $Z := \{x \in L_2 : \mathbb{E}x = 0\}$  является линейным подпространством  $L_2$ , так как

$$x, y \in Z \text{ и } \alpha, \beta \in \mathbb{R} \implies \mathbb{E}[\alpha x + \beta y] = \alpha \mathbb{E}[x] + \beta \mathbb{E}[y] = 0$$

Как и в  $\mathbb{R}^N$ , **ортонормированный базис** линейного подпространства  $S$  пространства  $L_2$  — множество  $\{u_1, \dots, u_K\} \subset S$  со свойством

$$\langle u_j, u_k \rangle = \mathbb{1}\{j = k\}$$

$$\text{и } \text{span}\{u_1, \dots, u_K\} = S$$

**Пример.** Пусть  $x \in L_2$  такой, что  $S := \text{span}\{\mathbb{1}, x\}$  множество случайных величин

$$\alpha + \beta x := \alpha \mathbb{1} + \beta x \quad \text{for scalars } \alpha, \beta \quad (10)$$

Если мы определим

$$u_1 := \mathbb{1} \quad \text{и} \quad u_2 := \frac{x - \mu}{\sigma_x}$$

Тогда

$$\langle u_1, u_2 \rangle = \mathbb{E}[u_1 u_2] = \mathbb{E}\left[\frac{x - \mu}{\sigma_x}\right] = 0$$

Ясно, что  $\|u_1\| = \|u_2\| = 1$ , так что эта пара ортонормирована

Также просто показать, что  $\text{span}\{u_1, u_2\} = \text{span}\{\mathbb{1}, x\}$ , значит  $\{u_1, u_2\}$  ортонормированный базис для  $S$

## Проекция в $L_2$

Как и в евклидовом случае, если  $\langle x, y \rangle = 0$ , мы говорим, что  $x$  и  $y$  **ортогональны**, и пишем  $x \perp y$

**Факт.** Если  $x, y \in L_2$  и  $\mathbb{E}x = 0$  или  $\mathbb{E}y = 0$ , то  $x \perp y \iff \text{cov}[x, y] = 0$

Возьмем  $y \in L_2$  и линейное подпространство  $S \subset L_2$ , мы ищем ближайший элемент  $\hat{y}$  множества  $S$  к  $y$

Близость по норме  $L_2$ , так что  $\hat{y}$  — решение минимизации  $\|y - z\|$  для всех  $z \in S$

Мы ищем

$$\hat{y} = \operatorname{argmin}_{z \in S} \|y - z\| = \operatorname{argmin}_{z \in S} \sqrt{\mathbb{E}[(y - z)^2]} \quad (11)$$

Следующая теорема имитирует теорему об ортогональной проекции, которую мы уже видели:

**Теорема.** (??) Пусть  $y \in L_2$  и  $S$  — любое непустое замкнутое линейное подпространство  $L_2$

Следующие утверждения верны:

1. задача оптимизации (11) имеет ровно одно решение
2.  $\hat{y} \in L_2$  является единственным решением

Утверждение, что  $S$  замкнуто значит, что  $\{x_n\} \subset S$  и  $x \in L_2$  с  $\|x_n - x\| \rightarrow 0$  подразумевает  $x \in S$  — условие истинное для всех линейных подпространств, с которыми мы хотим работать

Аналогично в случае  $\mathbb{R}^N$ , случайная переменная  $\hat{y}$  выше называется **ортгогональной проекцией  $y$  на  $S$**

Возьмем фиксированное  $S$ , операция

$$y \mapsto \text{ортгогональная проекция } y \text{ на } S$$

— функция из  $L_2$  в  $L_2$ :

- функция называется **ортгогональной проекцией на  $S$**
- функция обозначается как  $\mathbf{P}$
- мы пишем  $\mathbf{P} = \text{proj } S$

Для каждого  $y \in L_2$ ,  $\mathbf{P}y$  отображение  $y$  с помощью  $\mathbf{P}$ , которое является ортогональной проекцией  $\hat{y}$

- интерпретируем  $\mathbf{P}y$  как *лучший префиктор  $y$  из множества случайных величин, содержащегося в  $S$*

**Факт. (??)**

Если  $S$  — любое линейное подпространство  $L_2$ , и  $\mathbf{P} = \text{proj } S$ , то

1.  $\mathbf{P}$  — линейная функция.

Более того, для любых  $y \in L_2$ , получается

2.  $\mathbf{P}y \in S$ ,
3.  $y - \mathbf{P}y \perp S$ ,
4.  $\|y\|^2 = \|\mathbf{P}y\|^2 + \|y - \mathbf{P}y\|^2$ ,
5.  $\|\mathbf{P}y\| \leq \|y\|$ , и
6.  $\mathbf{P}y = y$  тогда и только тогда, когда  $y \in S$ .

В 1,  $\mathbf{P}$  линейна значит, что  $\mathbf{P}(\alpha x + \beta y) = \alpha \mathbf{P}x + \beta \mathbf{P}y$  для всех  $x, y \in L_2$  и  $\alpha, \beta \in \mathbb{R}$



**Факт.** (??) Пусть  $S_i$  — линейное подпространство  $L_2$  для  $i = 1, 2$  и  $\mathbf{P}_i = \text{proj } S_i$ . Если  $S_1 \subset S_2$ , то  $\mathbf{P}_1 \mathbf{P}_2 y = \mathbf{P}_1 y$  для всех  $y \in L_2$

**Факт.** (??) Если  $\{u_1, \dots, u_K\}$  — ортонормированный базис  $S$ , то для всех  $y \in L_2$ ,

$$\mathbf{P}y = \sum_{k=1}^K \langle y, u_k \rangle u_k \quad (12)$$

**Пример.** (??) Среднее случайной переменной  $x$  можно рассматривать как "лучший предиктор  $x$  среди множества констант"

Пусть  $S := \text{span}\{\mathbb{1}\}$ , где  $\mathbb{1} := \mathbb{1}_\Omega$ , и  $\mathbf{P} := \text{proj } S$

Объект  $\mathbf{P}x$  как раз лучший предиктор  $x$  в классе постоянных случайных величин

Не удивительно, что  $\mathbf{P}x = \mu \mathbb{1}$ , где  $\mu := \mathbb{E} x$

Самый простой способ проверить это — заметить, что  $\{\mathbb{1}\}$  является ортонормированным множеством, охватывающим  $S$ , и следовательно, по (12),

$$\mathbf{P}x = \langle x, \mathbb{1} \rangle \mathbb{1} = \mathbb{E}[x\mathbb{1}]\mathbb{1} = \mathbb{E}[x]\mathbb{1} = \mu \mathbb{1}$$

Вы можете также проверить утверждение, что  $\mu \mathbb{1}$  — проекция  $x$  на  $S$ , проверив условия в (ii) теоремы ??

## Пример.

Зафиксируем  $x, y \in L_2$  и рассмотрим проецирование  $y$  на  $S := \text{span}\{\mathbb{1}, x\}$

Множество  $S$  является множеством случайных величин

$$\alpha + \beta x := \alpha \mathbb{1} + \beta x \quad \text{для скаляров } \alpha, \beta$$

Задача проецирования  $y$  на  $S$  эквивалентна задаче поиска лучшего линейного предиктора из  $\S??$

Для реализации отзыва проекции

$$u_1 := \mathbb{1} \quad \text{и} \quad u_2 := \frac{x - \mu}{\sigma_x}$$

сформируем ортонормированный базис для  $S$

Пусть  $\mathbf{P} = \text{proj } S$ , применим факт (??), получаем

$$\mathbf{P}y = \langle y, u_1 \rangle u_1 + \langle y, u_2 \rangle u_2 = \mathbb{E}[y] + \frac{\text{cov}[x, y]}{\text{var}[x]}(x - \mathbb{E}[x])$$

Альтернативно

$$\mathbf{P}y = \alpha^* + \beta^* x$$

$$\text{где } \beta^* := \frac{\text{cov}[x, y]}{\text{var}[x]} \quad \text{и} \quad \alpha^* := \mathbb{E}[y] - \beta^* \mathbb{E}[x]$$

## Регрессия населения

Рассмотрим расширение задачи поиска лучшего линейного предиктора, описанной выше, до задачи, в которой информация для прогнозирования  $y$  — случайный вектор  $\mathbf{x}$  в  $\mathbb{R}^K$

Мы ищем  $L_2$  ортогональную проекцию  $y$  на линейное подпространство:

$\text{span}\{\mathbf{x}\} :=$  случайные величины вида  $\mathbf{x}^T \mathbf{b}$  для некоторых  $\mathbf{b} \in \mathbb{R}^K$

Предположим, что  $\mathbb{E}[\mathbf{x}^T \mathbf{x}] < \infty$

**Факт.** (??) Если  $\mathbb{E}[\mathbf{x}\mathbf{x}^\top]$  положительно определена, то проекция  $\mathbf{P}y$  любого  $y \in L_2$  на  $\text{span}\{\mathbf{x}\}$  определяется как

$$\hat{y} = \mathbf{x}^\top \mathbf{b}^* \quad \text{где} \quad \mathbf{b}^* := \mathbb{E}[\mathbf{x}\mathbf{x}^\top]^{-1} \mathbb{E}[\mathbf{x}y]$$

Упражнение ?? просит доказать вышеизложенный факт

Положительная определенность  $\mathbb{E}[\mathbf{x}\mathbf{x}^\top]$  обеспечивает обратимость, значит  $\mathbf{b}^*$  однозначно определено

По определению ортогональных проекций,  $\mathbf{b}^*$  обязательно удовлетворяет

$$\mathbf{b}^* = \underset{\mathbf{a} \in \mathbb{R}^K}{\operatorname{argmin}} \mathbb{E}[(y - \mathbf{x}^\top \mathbf{a})^2]$$

Задача линейного прогнозирования рассматривается также под названием **линейная регрессия населения**

- "население", потому что мы используем истинное совместное распределение  $(x, y)$ , когда считаем ожидания

У регрессии популяции есть аналог, называемый многомерной линейной регрессией, основанный на наблюдениях  $(x, y)$  – мы обсудим это в главе ??

# Измеримость

Мы не всегда хотим ограничиваться линейными прогнозами

Чтобы отказаться от требования линейности, изменим линейное подпространство, используемое для проецирования, из множества линейных функций  $x$  на множество произвольных функций  $x$

В результате, лучший предиктор — это условное математическое ожидание относительно  $x$



Подпространством произвольных действительных функций от  $x$  называются  $x$ -измеримые функции

Пусть  $\mathcal{G} := \{x_1, \dots, x_D\}$  — любое множество случайных величин и  $z$  — любая другая случайная величина

Переменная  $z$   **$\mathcal{G}$ -измерима**, если существует  $\mathcal{B}$ -измеримая функция  $g: \mathbb{R}^D \rightarrow \mathbb{R}$ , такая что

$$z = g(x_1, \dots, x_D)$$

- равенство между случайными величинами следует интерпретировать поточечно

$\mathcal{G}$  иногда упоминается как **информационное множество**

Мы также будем писать  $\mathbf{x} = (x_1, \dots, x_D)$  и говорить, что  $z$  является  $\mathbf{x}$ -измеримым

Аналогичная терминология будет использоваться для скаляров и матриц

- например, если  $\mathbf{X}$  — случайная матрица, то  $\mathbf{X}$ -измеримость означает  $\mathcal{G}$ -измеримость, когда  $\mathcal{G}$  содержит все элементы  $\mathbf{X}$

Интуиция:  $\mathcal{G}$ -измеримость  $z$  значит, что  $z$  полностью определяется элементами в  $\mathcal{G}$

Если  $z = \alpha x + \beta y$ , то  $z$   $\{x, y\}$ -измеримо (возьмем  $g(s, t) := \alpha s + \beta t$ )

$\mathcal{G} := \{x_1, \dots, x_N\}$ , то выборочное среднее  $\bar{x}_N := \frac{1}{N} \sum_{n=1}^N x_n$  является  $\mathcal{G}$ -измеримым.

**Пример.** Пусть  $x$  и  $y$  независимые и невырожденные

Тогда  $y$  не является  $x$ -измеримым. Если бы он таким являлся, мы бы имели  $y = g(x)$  для некоторой функции  $g$ , противоречащее независимости  $x$  и  $y$

**Пример.** Пусть  $y = \alpha$ , где  $\alpha$  — константа

Эта вырожденная случайная величина является  $\mathcal{G}$ -измеримой для любых информационных множеств  $\mathcal{G}$ , потому что  $y$  уже детерминированный

Например, если  $\mathcal{G} = \{x_1, \dots, x_p\}$ , то мы можем взять  $y = g(x_1, \dots, x_p) = \alpha + \sum_{i=1}^p 0x_i$

**Факт.** (??) Пусть  $\alpha, \beta$  — любые скаляры, и пусть  $x$  и  $y$  — случайные величины. Если  $x$  и  $y$  являются  $\mathcal{G}$ -измеримыми, то  $u := xy$  и  $v := \alpha x + \beta y$  также являются  $\mathcal{G}$ -измеримыми

Предположим, что  $\mathcal{G} \subset L_2$  и рассмотрим множество

$$L_2(\mathcal{G}) := \{\text{все } \mathcal{G}\text{-измеримые случайные величины в } L_2\}$$

С учетом факта ??:

**Факт.** Для любых  $\mathcal{G} \subset L_2$ , множество  $L_2(\mathcal{G})$  — линейное подпространство  $L_2$

Это дает нам подпространство для проецирования, что позволяет нам определять условные математические ожидания

**Факт.** (??) Если  $\mathcal{G} \subset \mathcal{H}$  и  $z$  является  $\mathcal{G}$ -измеримой, то  $z$  является  $\mathcal{H}$ -измеримой.

Если  $z$  известен, когда переменные в  $\mathcal{G}$  известны, то он точно известен, когда дополнительная информация, предоставленная  $\mathcal{H}$ , доступна

**Пример.** Пусть  $x_1$ ,  $x_2$  и  $y$  — случайные величины и пусть

$$\mathcal{G} := \{x_1\} \subset \{x_1, x_2\} =: \mathcal{H}$$

Если  $y$  является  $\mathcal{G}$ -измеримой, то  $y = g(x_1)$  для некоторых  $\mathcal{B}$ -измеримых  $g$ . Но тогда  $y$  будет также являться  $\mathcal{H}$ -измеримой. Например, мы можем написать  $y = h(x_1, x_2)$ , где  $h(x_1, x_2) = g(x_1) + 0x_2$ .

**Факт.** (5.2.12) Если  $\mathcal{G} \subset \mathcal{H}$ , то  $L_2(\mathcal{G}) \subset L_2(\mathcal{H})$

## Условное математическое ожидание

Пусть  $\mathcal{G} \subset L_2$  и  $y$  — некоторая случайная величина  $L_2$

**Условное математическое ожидание**  $y$  при данном  $\mathcal{G}$  записывается как  $\mathbb{E}[y \mid \mathcal{G}]$  или  $\mathbb{E}^{\mathcal{G}}[y]$  и определяется как

$$\mathbb{E}[y \mid \mathcal{G}] := \operatorname{argmin}_{z \in L_2(\mathcal{G})} \|y - z\| \quad (13)$$

$\mathbb{E}[y | \mathcal{G}]$  — лучший предиктор  $y$  при данной информации, содержащейся в  $\mathcal{G}$



Решение такой задачи минимизации вообще существует? И является ли оно единственным?

- да и да

Имеется

$$\mathbb{E}[y \mid \mathcal{G}] = \mathbf{P}y \quad , \text{ когда } \mathbf{P} := \text{proj } L_2(\mathcal{G})$$

По теореме об ортогональной проекции, проекция существует и является единственной

Альтернативное (и эквивалентное) определение условного математического ожидания

Функция  $\hat{y}$ , где  $\hat{y} \in L_2$ , — **условное математическое ожидание**  $y$  при данном  $\mathcal{G}$ , если

1.  $\hat{y}$  является  $\mathcal{G}$ -измеримой и
2.  $\mathbb{E}[\hat{y}z] = \mathbb{E}[yz]$  для всех  $\mathcal{G}$ -измеримых  $z \in L_2$ .

Для удобства мы также будем использовать такие символы, как  $\mathbb{E}[y \mid x_1, \dots, x_D]$  или  $\mathbb{E}[y \mid \mathbf{x}]$

- так же, как  $\mathbb{E}[y \mid \mathcal{G}]$ , когда  $\mathcal{G}$  определяется как информационное множество, содержащее переменные, на которые мы ставим условие

**Пример.** Если  $x$  и  $u$  независимые,  $\mathbb{E}u = 0$  и  $y = x + u$ , то  $\mathbb{E}[y | x] = x$ . Чтобы доказать это, нам нужно показать, что  $x$  удовлетворяет условиям 1–2 выше

Ясно, что  $x$  является  $x$ -измеримой

Для 2. мы должны показать, что  $\mathbb{E}[xz] = \mathbb{E}[yz]$  для всех  $x$ -измеримых  $z$ . Это означает утверждение

$$\mathbb{E}[xg(x)] = \mathbb{E}[(x + u)g(x)]$$

для любых  $\mathcal{B}$ -измеримых  $g$ , которое является верным из-за независимости и  $\mathbb{E}u = 0$

**Факт.** (??) Возьмем  $\mathbf{x} \in \mathbb{R}^D$  и  $y$  в  $L_2$ , существует  $\mathcal{B}$ -измеримая функция  $f^*: \mathbb{R}^D \rightarrow \mathbb{R}$ , такая что  $\mathbb{E}[y | \mathbf{x}] = f^*(\mathbf{x})$

Частная функция  $f^*$ , удовлетворяющая  $f^*(\mathbf{x}) = \mathbb{E}[y | \mathbf{x}]$  называется **функцией регрессии**  $y$  при данном  $\mathbf{x}$

**Пример.** Если  $x$  и  $y$  — случайные величины и  $p(y | x)$  — условная функция плотности  $y$  при данном  $x$ , то

$$\mathbb{E}[y | x] = \int t p(t | x) dt$$

Докажите в качестве упражнения ?? в ЕТ

**Факт.** (??) Пусть  $x$  и  $y$  — случайные величины в  $L_2$ , пусть  $\alpha$  и  $\beta$  — скаляры, и пусть  $\mathcal{G}$  и  $\mathcal{H}$  — подмножества  $L_2$ . Следующие свойства выполняются:

1. Линейность:  $\mathbb{E}[\alpha x + \beta y \mid \mathcal{G}] = \alpha \mathbb{E}[x \mid \mathcal{G}] + \beta \mathbb{E}[y \mid \mathcal{G}]$
2. Если  $\mathcal{G} \subset \mathcal{H}$ , то  $\mathbb{E}[\mathbb{E}[y \mid \mathcal{H}] \mid \mathcal{G}] = \mathbb{E}[y \mid \mathcal{G}]$  и  $\mathbb{E}[\mathbb{E}[y \mid \mathcal{G}]] = \mathbb{E}[y]$  (**закон повторных ожиданий**)
3. Если  $y$  не зависит от переменных в  $\mathcal{G}$ , то  $\mathbb{E}[y \mid \mathcal{G}] = \mathbb{E}[y]$ .
4. Если  $y$  является  $\mathcal{G}$ -измеримой, то  $\mathbb{E}[y \mid \mathcal{G}] = y$
5. Если  $x$  является  $\mathcal{G}$ -измеримой, то  $\mathbb{E}[xy \mid \mathcal{G}] = x \mathbb{E}[y \mid \mathcal{G}]$  (**условный детерминизм**)

Резюмируем: при данном  $y \in L_2$  и случайном векторе  $\mathbf{x}$  в  $\mathbb{R}^D$ , условное математическое ожидание  $\mathbb{E}[y | \mathbf{x}]$  — функция  $f^*$  переменной  $\mathbf{x}$ , называемая функцией регрессии  $y$  при данном  $\mathbf{x}$ , такая что:

$$f^*(\mathbf{x}) = \operatorname{argmin}_{g \in G} \mathbb{E}[(y - g(\mathbf{x}))^2] \quad (14)$$

где  $G$  — множество функций из  $\mathbb{R}^D$  в  $\mathbb{R}$  с  $g(\mathbf{x}) \in L_2$

Для любых  $g \in G$ , мы также имеем

$$\mathbb{E}[(y - g(\mathbf{x}))^2] = \mathbb{E}[(y - f^*(\mathbf{x}))^2] + \mathbb{E}[(f^*(\mathbf{x}) - g(\mathbf{x}))^2] \quad (15)$$

Это подразумевает, что (14), потому что  $(f^*(\mathbf{x}) - g(\mathbf{x}))^2 \geq 0$

Чтобы доказать (15), пусть  $f^*$  — функция регрессии, возьмем любой  $g \in G$  и заметим, что

$$\begin{aligned}(y - g(\mathbf{x}))^2 &= (y - f^*(\mathbf{x}) + f^*(\mathbf{x}) - g(\mathbf{x}))^2 \\&= (y - f^*(\mathbf{x}))^2 + 2(y - f^*(\mathbf{x}))(f^*(\mathbf{x}) - g(\mathbf{x})) \\&\quad + (f^*(\mathbf{x}) - g(\mathbf{x}))^2\end{aligned}$$

Рассмотрим математическое ожидание перемножения разных величин. Из закона повторных ожиданий:

$$\begin{aligned}\mathbb{E} \{ (y - f^*(\mathbf{x}))(f^*(\mathbf{x}) - g(\mathbf{x})) \} & \tag{16} \\&= \mathbb{E} \{ \mathbb{E} [(y - f^*(\mathbf{x}))(f^*(\mathbf{x}) - g(\mathbf{x})) \mid \mathbf{x}] \}\end{aligned}$$

Используем условный детерминизм, перепишем часть в фигурных скобках справа как

$$(f^*(\mathbf{x}) - g(\mathbf{x}))\mathbb{E}[(y - f^*(\mathbf{x})) | \mathbf{x}]$$

Для второй части данного умножения

$$\mathbb{E}[y - f^*(\mathbf{x}) | \mathbf{x}] = \mathbb{E}[y | \mathbf{x}] - \mathbb{E}[f^*(\mathbf{x}) | \mathbf{x}] = \mathbb{E}[y | \mathbf{x}] - f^*(\mathbf{x}) = 0$$

Значит математическое ожидание в (16) равно нулю —  
Уравнение (15) следует



## Векторный случай

Возьмем случайные матрицы  $\mathbf{X}$  и  $\mathbf{Y}$

$$\mathbb{E}[\mathbf{Y} | \mathbf{X}] := \begin{pmatrix} \mathbb{E}[y_{11} | \mathbf{X}] & \cdots & \mathbb{E}[y_{1K} | \mathbf{X}] \\ \vdots & & \vdots \\ \mathbb{E}[y_{N1} | \mathbf{X}] & \cdots & \mathbb{E}[y_{NK} | \mathbf{X}] \end{pmatrix}$$

Мы также определим

1.  $\text{cov}[\mathbf{x}, \mathbf{y} | \mathbf{Z}] := \mathbb{E}[\mathbf{x}\mathbf{y}^T | \mathbf{Z}] - \mathbb{E}[\mathbf{x} | \mathbf{Z}]\mathbb{E}[\mathbf{y} | \mathbf{Z}]^T$
2.  $\text{var}[\mathbf{x} | \mathbf{Z}] := \mathbb{E}[\mathbf{x}\mathbf{x}^T | \mathbf{Z}] - \mathbb{E}[\mathbf{x} | \mathbf{Z}]\mathbb{E}[\mathbf{x} | \mathbf{Z}]^T$

Свойства скалярных условных математических ожиданий в факте ?? переходят к случаю с матрицами

Неполный список:

**Факт.** (??) Если  $\mathbf{X}$ ,  $\mathbf{Y}$  и  $\mathbf{Z}$  — случайные матрицы и  $\mathbf{A}$  и  $\mathbf{B}$  постоянные и согласованные, то

1.  $\mathbb{E}[\mathbf{Y} | \mathbf{Z}]^T = \mathbb{E}[\mathbf{Y}^T | \mathbf{Z}]$ .
2.  $\mathbb{E}[\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y} | \mathbf{Z}] = \mathbf{A}\mathbb{E}[\mathbf{X} | \mathbf{Z}] + \mathbf{B}\mathbb{E}[\mathbf{Y} | \mathbf{Z}]$ .
3.  $\mathbb{E}[\mathbb{E}[\mathbf{Y} | \mathbf{X}]] = \mathbb{E}[\mathbf{Y}]$  и  $\mathbb{E}[\mathbb{E}[\mathbf{Y} | \mathbf{X}, \mathbf{Z}] | \mathbf{X}] = \mathbb{E}[\mathbf{Y} | \mathbf{X}]$ .
4. Если  $\mathbf{X}$  и  $\mathbf{Y}$  независимые, то  $\mathbb{E}[\mathbf{Y} | \mathbf{X}] = \mathbb{E}[\mathbf{Y}]$ .
5. Если  $g(\mathbf{X})$  — матрица, зависящая только от  $\mathbf{X}$ , то
  - 5.1  $\mathbb{E}[g(\mathbf{X}) | \mathbf{X}] = g(\mathbf{X})$
  - 5.2  $\mathbb{E}[g(\mathbf{X}) \mathbf{Y} | \mathbf{X}] = g(\mathbf{X}) \mathbb{E}[\mathbf{Y} | \mathbf{X}]$  и  
 $\mathbb{E}[\mathbf{Y} g(\mathbf{X}) | \mathbf{X}] = \mathbb{E}[\mathbf{Y} | \mathbf{X}] g(\mathbf{X})$